Теория параллелизма

# Отчет
# Уравнение теплопроводности

Выполнил: Пучков Владислав, гр. 22933
Дата 20.05.2024

Цель: Реализовать решение уравнения теплопроводности в двумерной области с использованием разностной схемы (пятиточечный шаблон) на равномерных сетках. Программа должна учитывать линейную интерполяцию на границах и заданные значения в углах, ограничивать точность до 10^−6 и максимальное число итераций до 10^6. Реализация должна быть на C++ с использованием OpenACC для переноса на GPU. Необходимо сравнить производительность на CPU и GPU, провести профилирование и оптимизацию кода.

Используемый компилятор: pgc++ 23.11-0

Используемый профилировщик: NVIDIA Nsight Systems

Как производили замер времени работы: При помощи Библиотеки chrono замерил время начала и конца цикла итераций

## Выполнение на CPU

### **CPU**-onecore

| Размер сетки | Время выполнения (сек) | Точность | Количество операций |
|---|---|---|---|
| **128*128** | 0,65 | 0.000001 | 31000 |
| **256*256** | 7,98 | 0.000001 | 110000 |
| **512*512** | 103,4 | 0.000001 | 340000 |

### **CPU**-multicore

| Размер сетки | Время выполнения (сек) | Точность | Количество операций |
|---|---|---|---|
| **128*128** | 0,52 | 0.000001 | 31000 |
| **256*256** | 1,81 | 0.000001 | 110000 |
| **512*512** | 34,1 | 0.000001 | 340000 |
| **1024*1024** | 321,62 | 0.000001 | 1000000 |

**Диаграмма сравнения** время работы CPU-one и **CPU**-multi

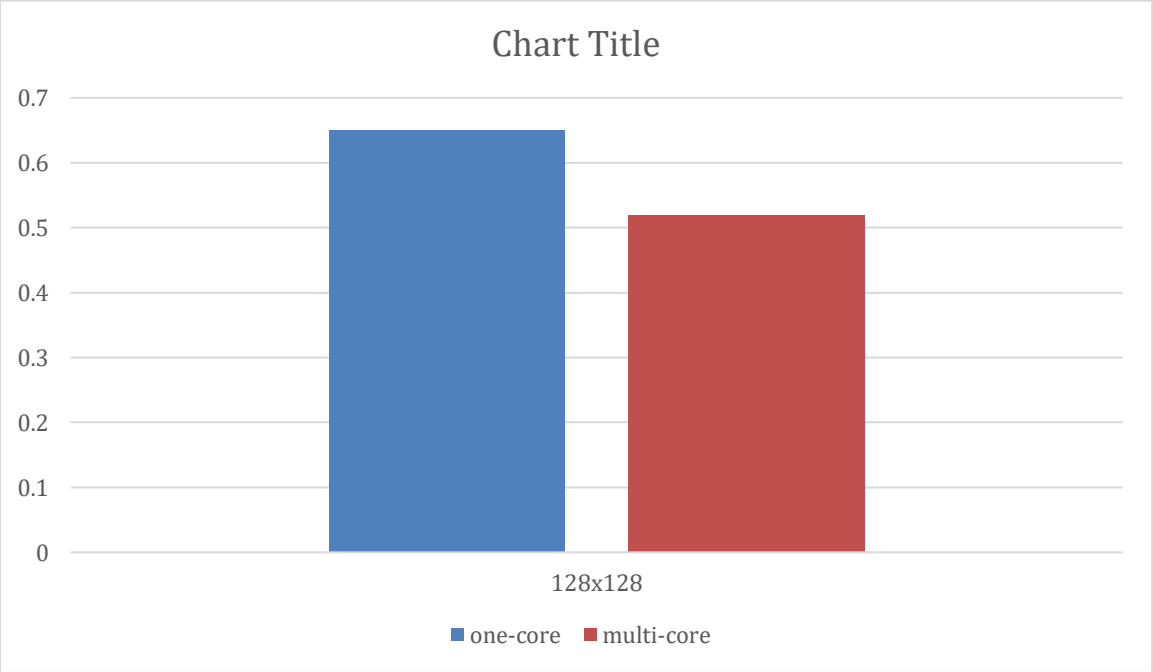


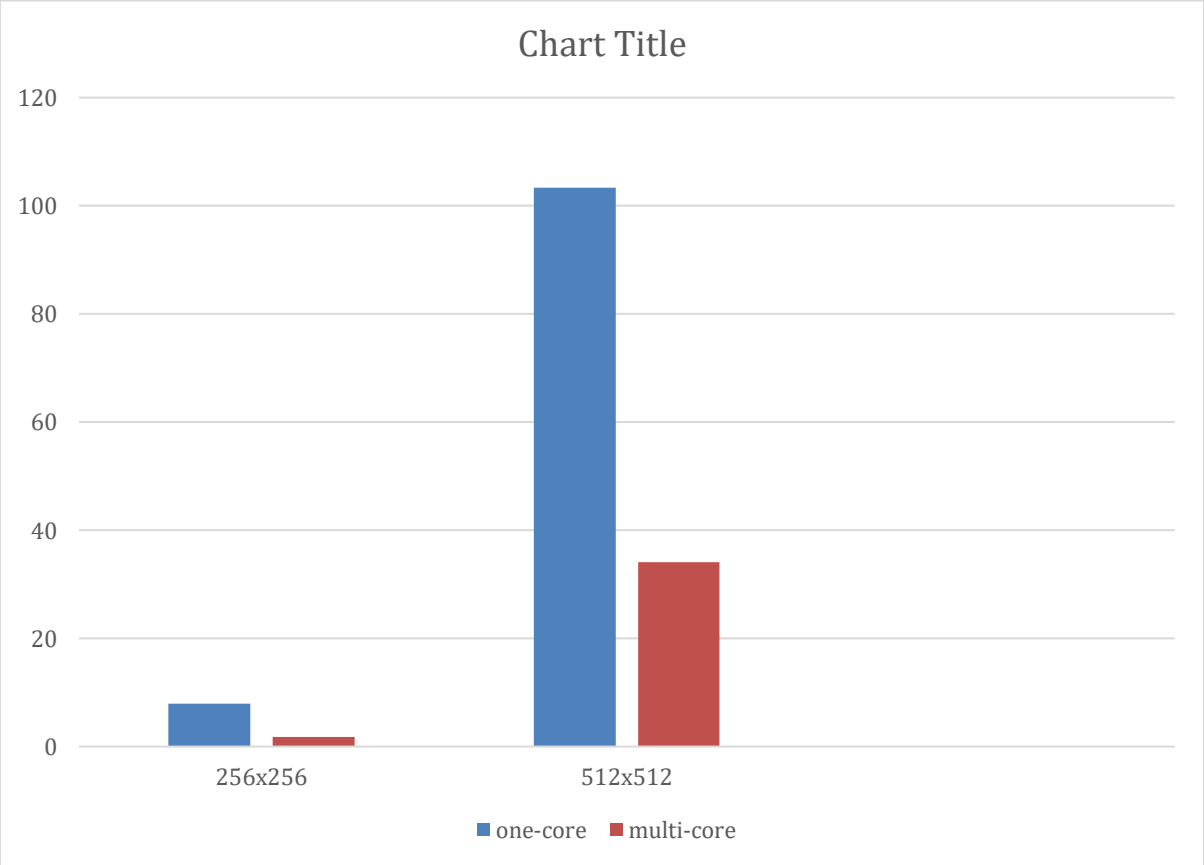

# Выполнение на GPU

## **Этапы оптимизации** на сетке 1024*1024

| Этап | Время выполнения | Точность | Количество итераций | Комментарии |
|---|---|---|---|---|
| 1 | 71,83 | >0.000001 | 1000000 | Замена swap через temp на  swap через указатели |
| 2 | 44,56 | >0.000001 | 1000000 | Возвращение ошибки каждые 1000 операций |
| 3 | 42,768 | >0.000001 | 1000000 | Замена распараллеливания цикла на #pragma acc parallel loop independent collapse(2) vector vector_length(256) gang num_gangs(1024) present(currentMatrix, previousMatrix) |
| 4 | 34,987 | >0.000001 | 1000000 | Выбор самой свободной видеокарты через библиотеку #include <openacc.h> и команду acc_set_device_num( N, acc_device_nvidia ); |

# Диаграмма оптимизации

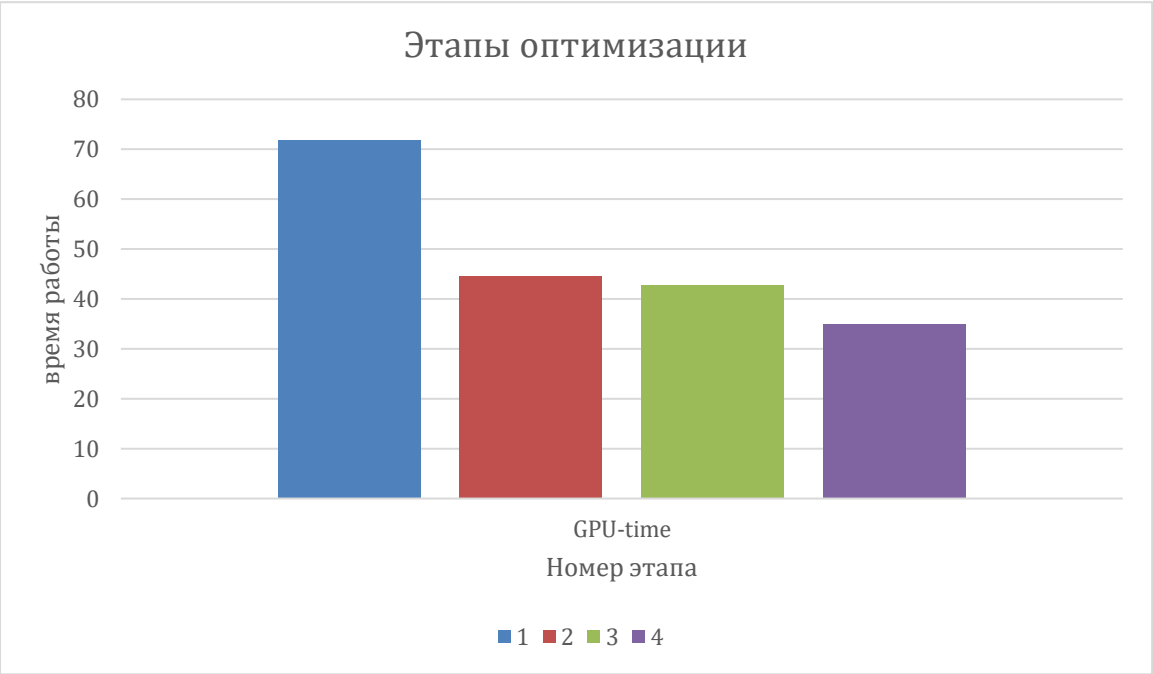

Профилирование:

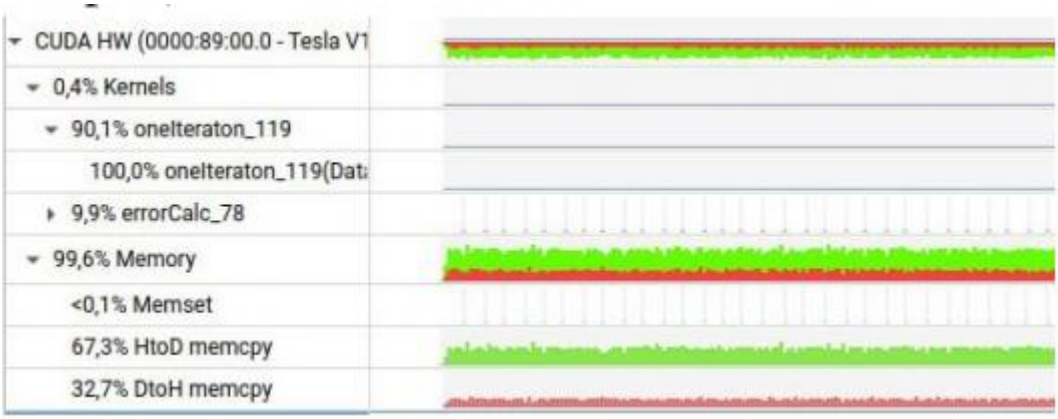


Большая часть времени GPU отправляет данные на каждой итерации, вместо вычислений

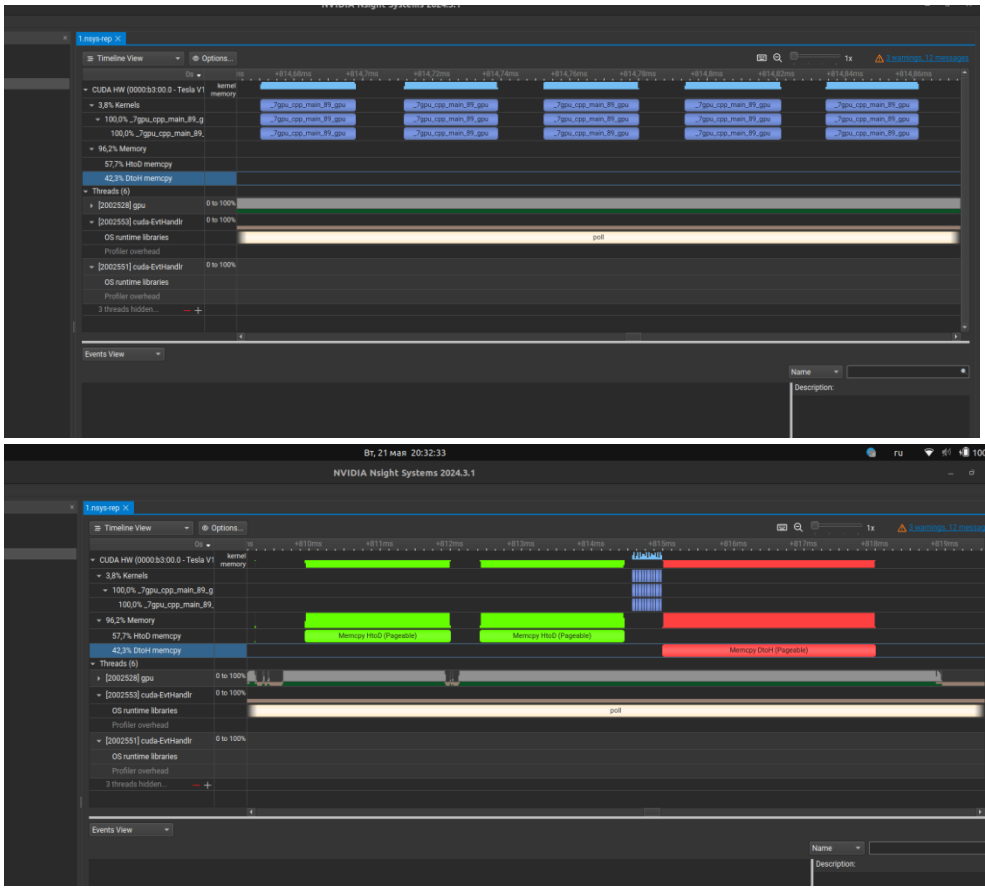

скорость работы была увеличена за счёт того что ошибка вычисляется не на каждой итерации, так как максимизация переменной среди потоков требует времени на синхронизацию между потоками.

# GPU - оптимизированный вариант

| Размер сетки | Время выполнения(с) | Точность | Количество операций |
|---|---|---|---|
| **128*128** | 0,43 | 0.000001 | 40000 |
| **256*256** | 1,27 | 0.000001 | 110000 |
| **512*512** | 4,2 | 0.000001 | 340000 |
| **1024*1024** | 34,8 | >0.000001 | 1000000 |

# Диаграмма сравнения времени работы CPU-one, CPU-multi, GPU(оптимизированный вариант) для разных размеров сеток

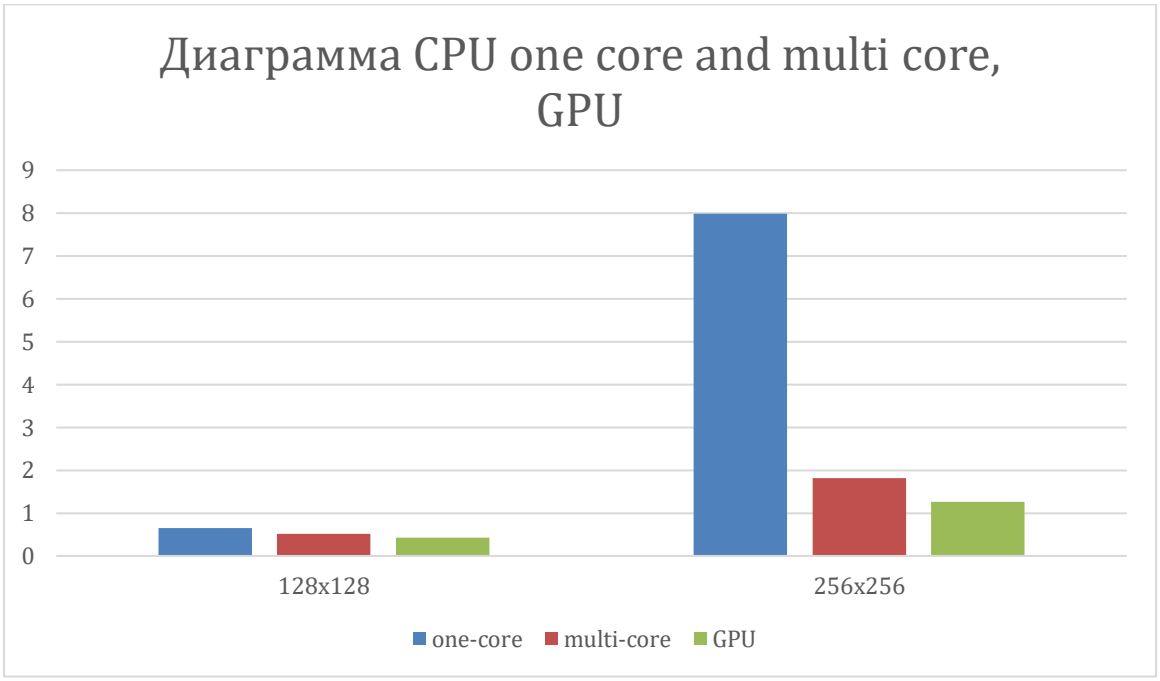


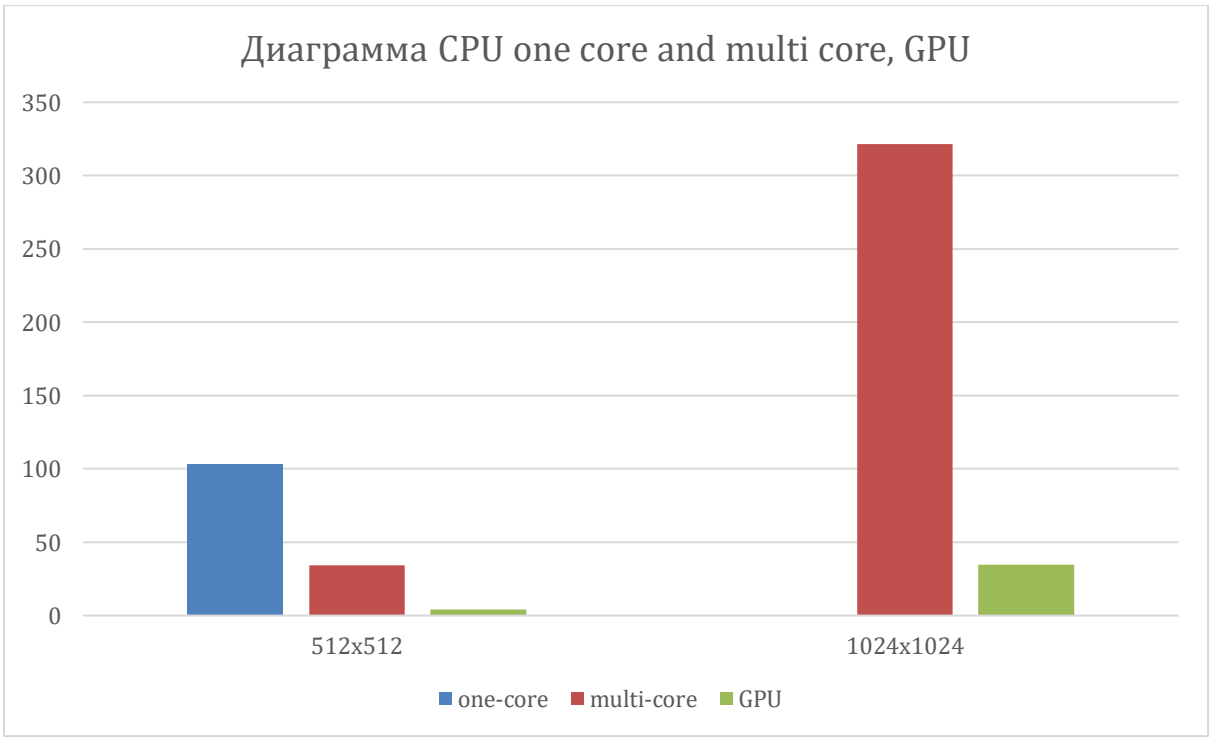

GPU - **оптимизированный** вариант + cuBLAS

| Размер сетки | Время выполнения(с) | Точность | Количество операций |
|---|---|---|---|
| **128*128** | 0,5 | 0.000001 | 40000 |
| **256*256** | 1,63 | 0.000001 | 110000 |
| **512*512** | 5,63 | 0.000001 | 340000 |
| **1024*1024** | 33,82 | >0.000001 | 1000000 |

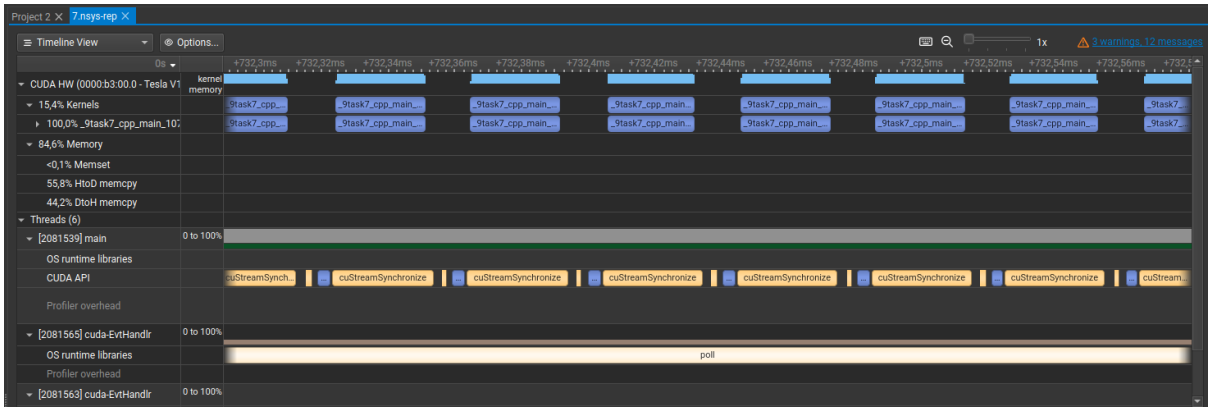


## Диаграмма GPU и GPU+cuBLAS

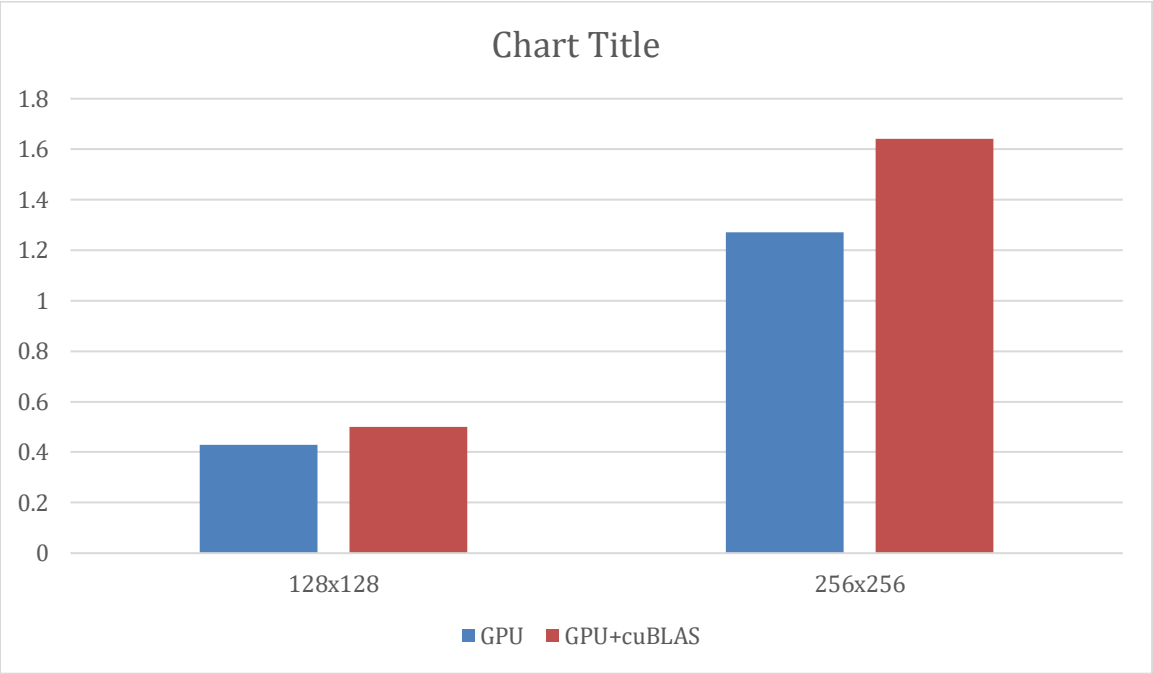


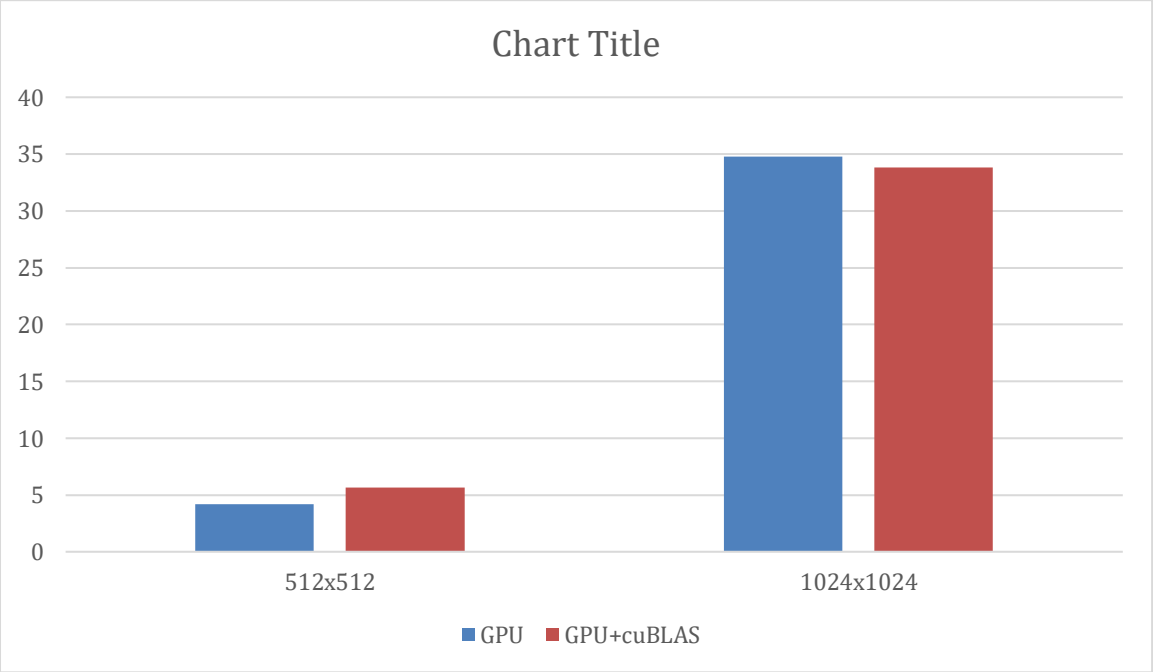


**Вывод**: GPU+ cuBLAS работает чуть быстрее чем без cuBLAS’а.

Диаграмма **CPU one-core, CPU multi-core, GPU и GPU+cuBLAS**

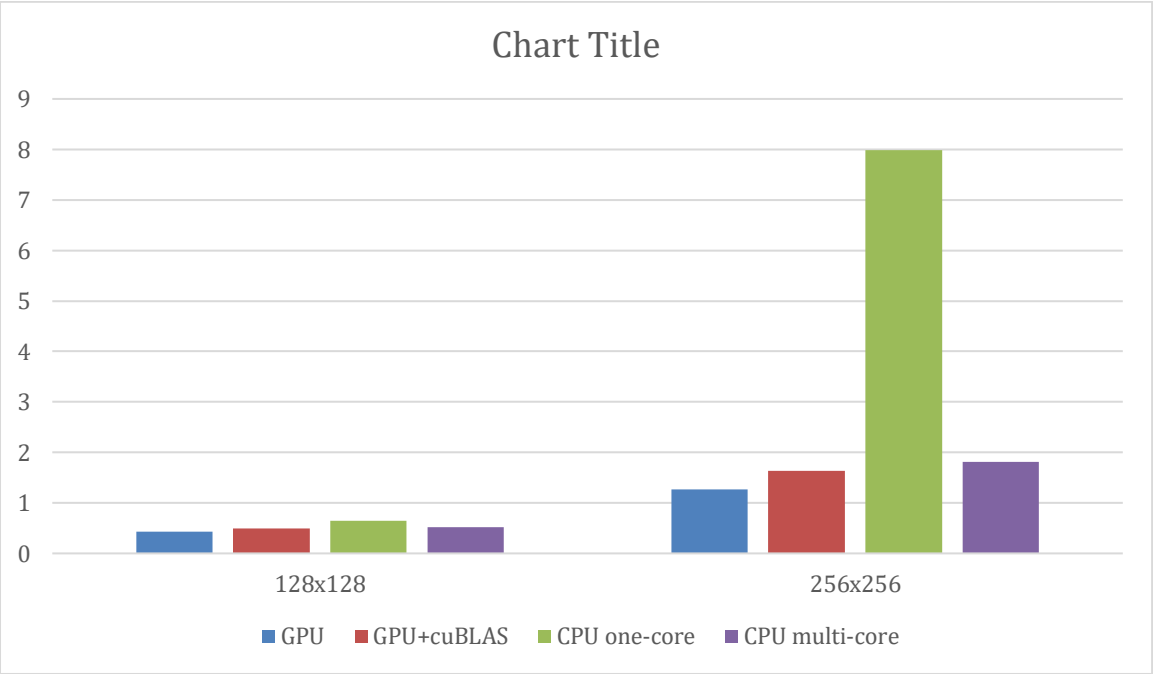


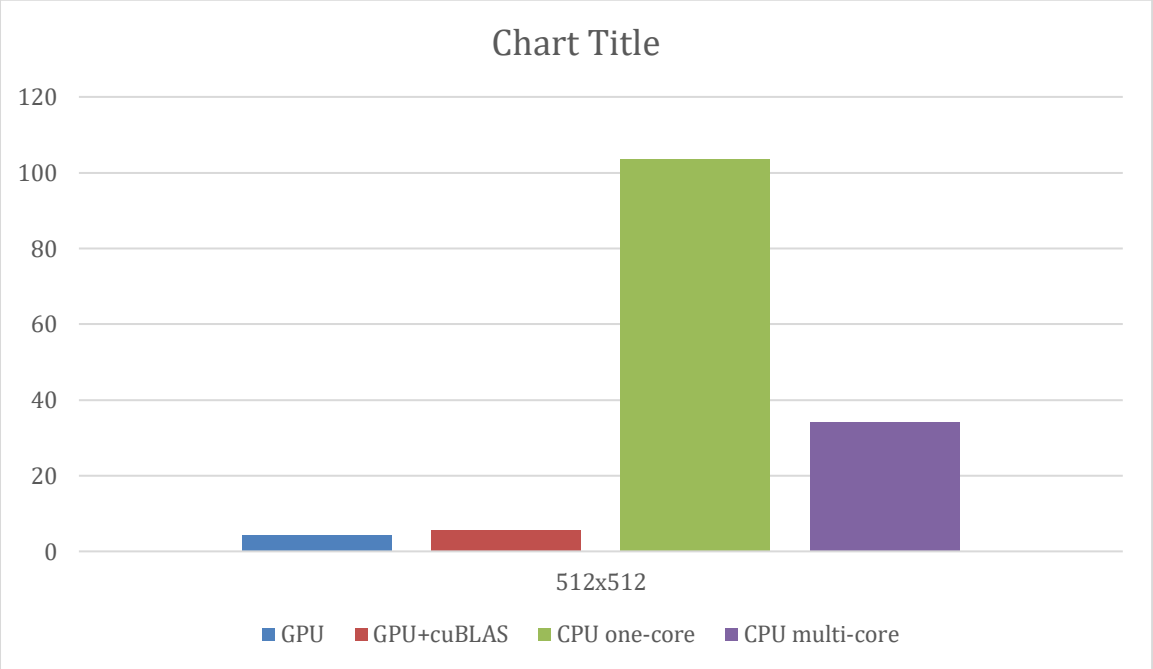

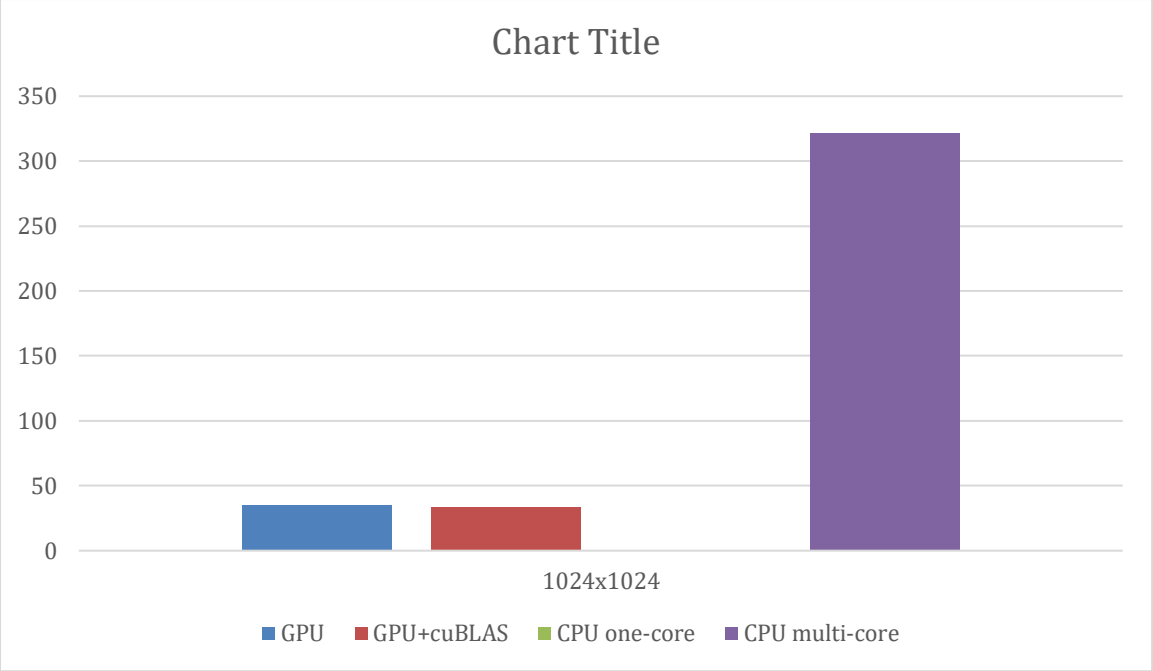
Chart Title
350
300
250
200
150
100
50
0
1024x1024
GPU
GPU+cuBLAS
CPU one-core
CPU multi-core

GPU (CUDA)

| Размер сетки | Время выполнения(с) | Точность | Количество операций |
|---|---|---|---|
| **128*128** | 0,063 | 0.000001 | 31000 |
| **256*256** | 0,224 | 0.000001 | 103000 |
| **512*512** | 1,328 | 0.000001 | 340000 |
| **1024*1024** | 24,253 | >0.000001 | 1000000 |

# Профилирование на сетке 50x50

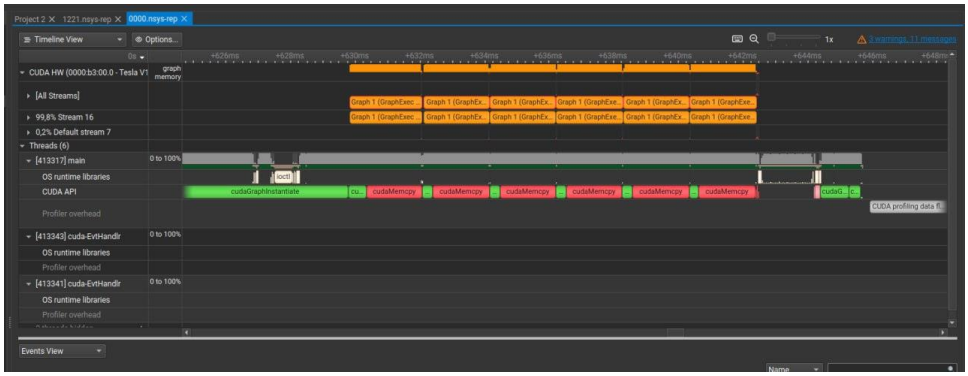

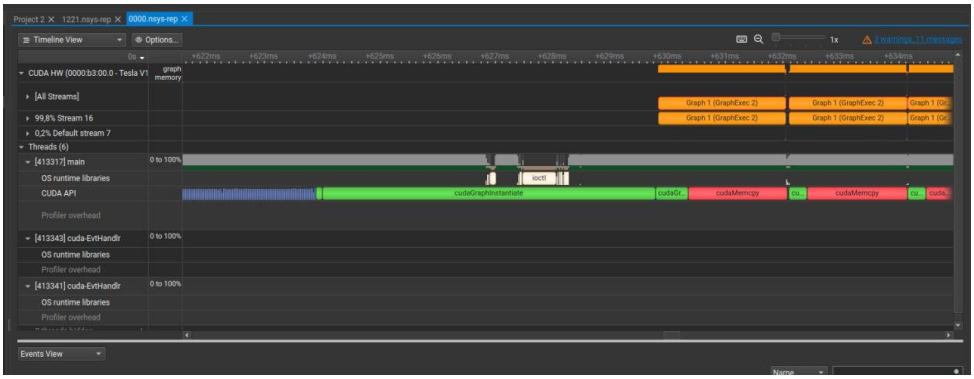

# Профилирование на сетке 1024x1024

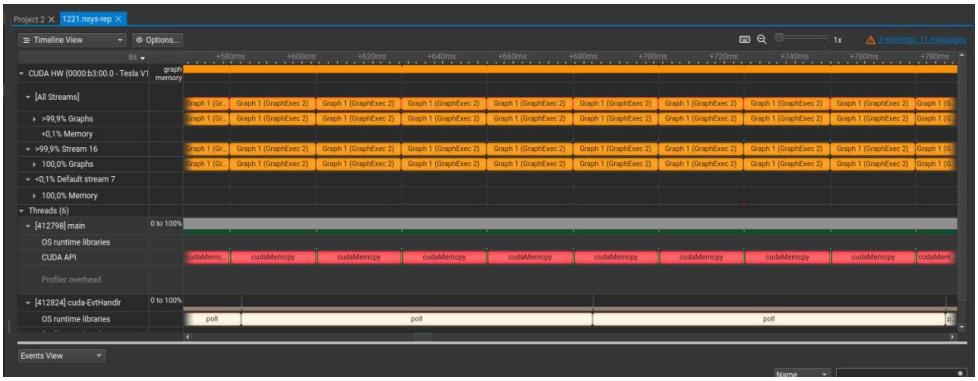

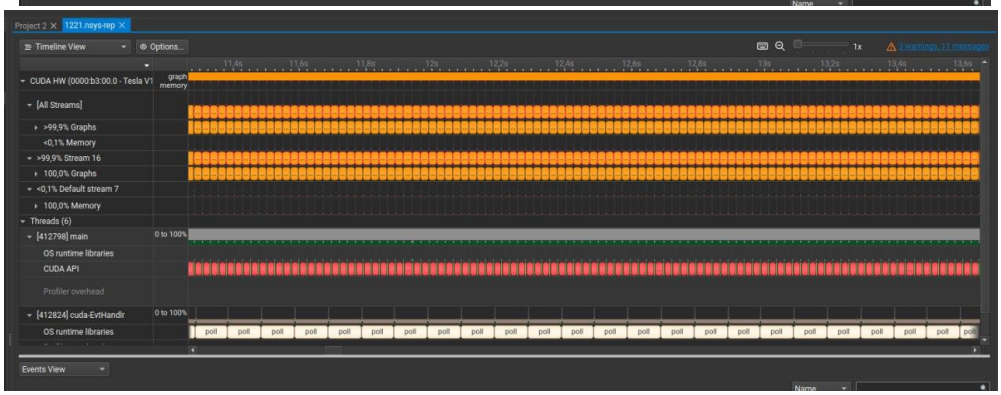

<u>Вывод профилирования:</u> Вычисления занимают примерно 86% от общей работы GPU, также благодаря использованию cudaGraph мы вызываем только его, а не каждую операцию отдельно, что также добавляет прирост оптимизации.

Диаграмма **CPU one-core, CPU multi-core, GPU и GPU+cuBLAS, GPU(CUDA)**

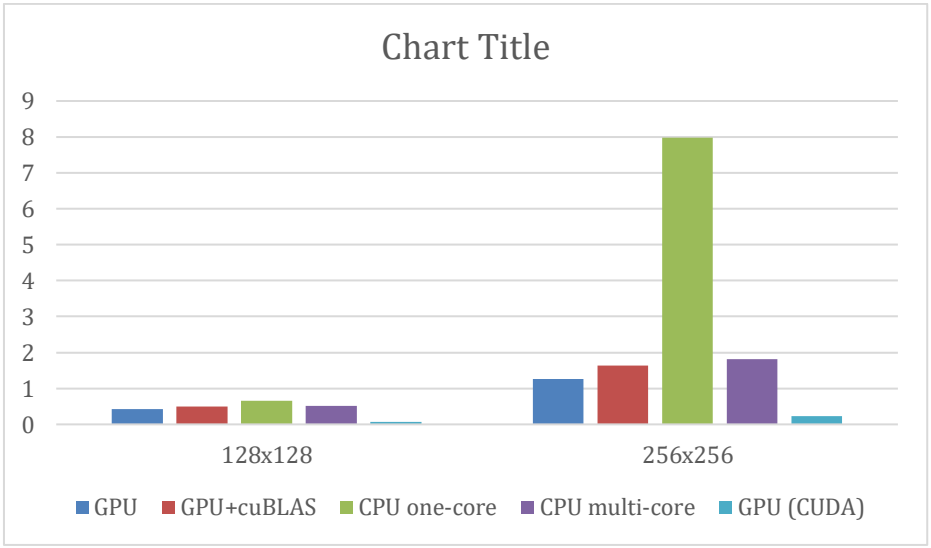


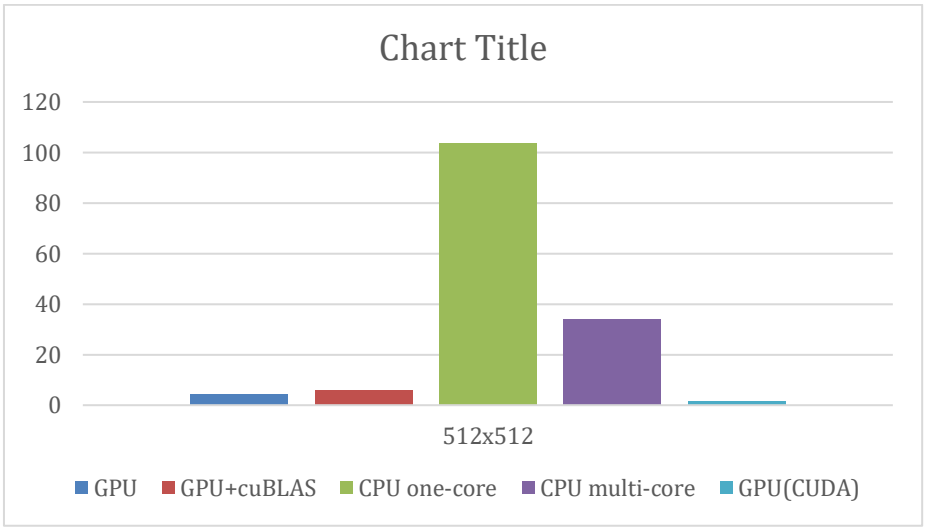


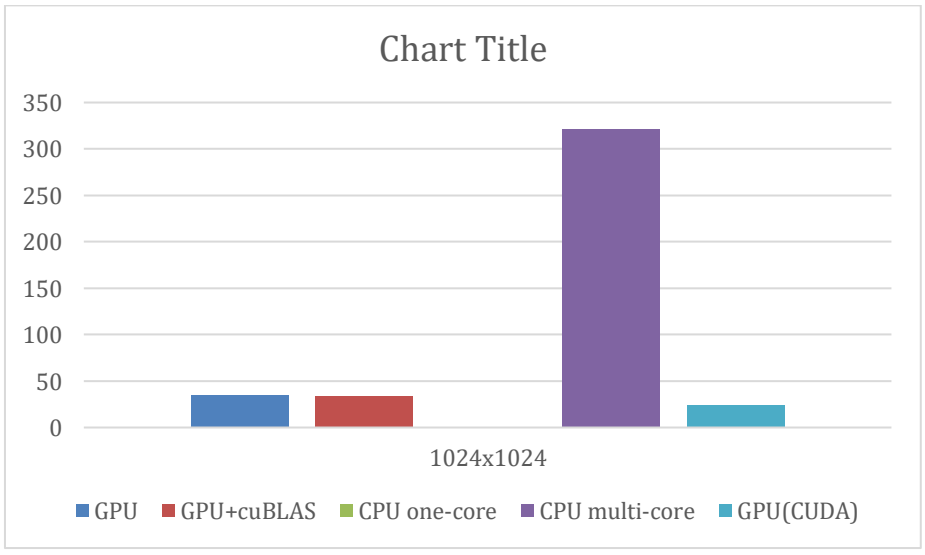

10x10 (CUDA)

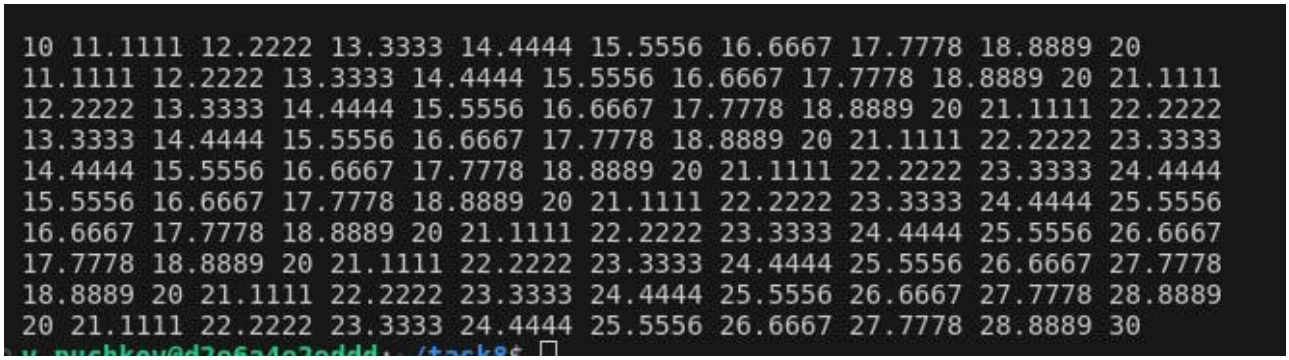


13x13 (CUDA)

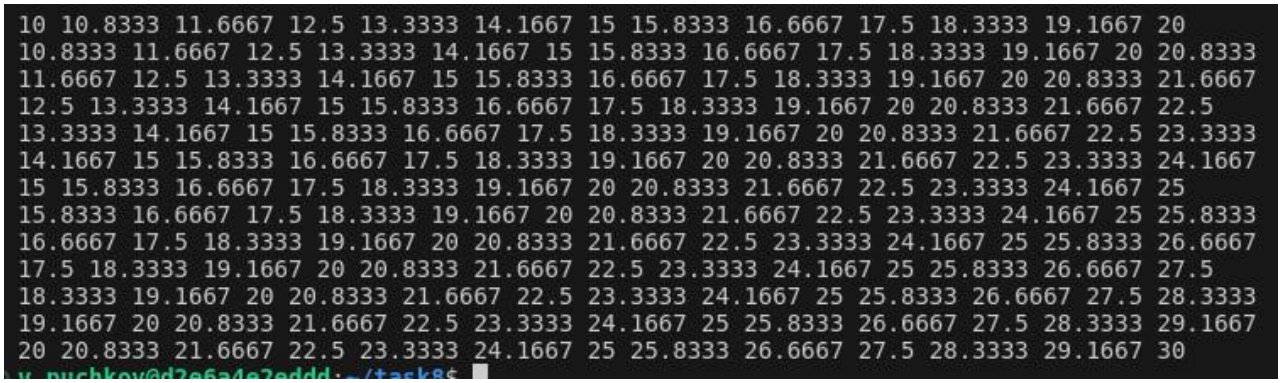

10x10

```
v.puchkov@d2e6a4e2eddd:~/task6_k/gpu$ ./gpu
Итерация: 10000 ошибка: 0
Вреся: 121 мс, Ошибка: 0, Итерации: 10000
10 11.1111 12.2222 13.3333 14.4444 15.5556 16.6667 17.7778 18.8889 20
11.1111 12.2222 13.3333 14.4444 15.5556 16.6667 17.7778 18.8889 20 21.1111
12.2222 13.3333 14.4444 15.5556 16.6667 17.7778 18.8889 20 21.1111 22.2222
13.3333 14.4444 15.5556 16.6667 17.7778 18.8889 20 21.1111 22.2222 23.3333
14.4444 15.5556 16.6667 17.7778 18.8889 20 21.1111 22.2222 23.3333 24.4444
15.5556 16.6667 17.7778 18.8889 20 21.1111 22.2222 23.3333 24.4444 25.5556
16.6667 17.7778 18.8889 20 21.1111 22.2222 23.3333 24.4444 25.5556 26.6667
17.7778 18.8889 20 21.1111 22.2222 23.3333 24.4444 25.5556 26.6667 27.7778
18.8889 20 21.1111 22.2222 23.3333 24.4444 25.5556 26.6667 27.7778 28.8889
20 21.1111 22.2222 23.3333 24.4444 25.5556 26.6667 27.7778 28.8889 30
```

13x13

```
Итерация: 10000 ошибка: 0
Вреся: 112 мс, Ошибка: 0, Итерации: 10000
10 10.8333 11.6667 12.5 13.3333 14.1667 15 15.8333 16.6667 17.5 18.3333 19.1667 20
10.8333 11.6667 12.5 13.3333 14.1667 15 15.8333 16.6667 17.5 18.3333 19.1667 20 20.8333
11.6667 12.5 13.3333 14.1667 15 15.8333 16.6667 17.5 18.3333 19.1667 20 20.8333 21.6667
12.5 13.3333 14.1667 15 15.8333 16.6667 17.5 18.3333 19.1667 20 20.8333 21.6667 22.5
13.3333 14.1667 15 15.8333 16.6667 17.5 18.3333 19.1667 20 20.8333 21.6667 22.5 23.3333
14.1667 15 15.8333 16.6667 17.5 18.3333 19.1667 20 20.8333 21.6667 22.5 23.3333 24.1667
15 15.8333 16.6667 17.5 18.3333 19.1667 20 20.8333 21.6667 22.5 23.3333 24.1667 25
15.8333 16.6667 17.5 18.3333 19.1667 20 20.8333 21.6667 22.5 23.3333 24.1667 25 25.8333
16.6667 17.5 18.3333 19.1667 20 20.8333 21.6667 22.5 23.3333 24.1667 25 25.8333 26.6667
17.5 18.3333 19.1667 20 20.8333 21.6667 22.5 23.3333 24.1667 25 25.8333 26.6667 27.5
18.3333 19.1667 20 20.8333 21.6667 22.5 23.3333 24.1667 25 25.8333 26.6667 27.5 28.3333
19.1667 20 20.8333 21.6667 22.5 23.3333 24.1667 25 25.8333 26.6667 27.5 28.3333 29.1667
20 20.8333 21.6667 22.5 23.3333 24.1667 25 25.8333 26.6667 27.5 28.3333 29.1667 30
```

Вывод: Лучше всего GPU себя показывает на больших матрицах, на небольших размерах GPU, CPU-onecore, CPU-milticore – очень близки по времени. Возврат с GPU на CPU ошибки при большом количестве операций, необязательно проверять ошибку каждый раз, так как копирование занимает также время

Вывод **cuBLAS:** если выполнять операцию редукции (вычисление максимального значения ошибки) на графическом процессоре реализовать через вызовы функций из библиотеки cuBLAS, то это дает небольшое уменьшение время выполнения программы.

Вывод **CUDA**: Если выполнять операцию редукции (вычисление максимального значения ошибки) на графическом процессоре реализовать через вызовы функций из библиотеки CUB на уровне блока и применить CUDA graph для итераций между подсчетами ошибки, дает очень большое время уменьшение время выполнения программы на каждом размере сетке из протестированных.